머신러닝 리포트 - 분류1

로지스틱 회귀(이진 분류, 2개의 카테고리)

목차

- 1. 시나리오
- 2. 목표
- 3. 프로세스
 - 3-1. 흐름도
 - 3-2. Load Data
 - 3-3. Pre-Processing
 - 3-4. Modeling
 - 3-5. Evaluation
- 4. 결론

1. 시나리오

- 파형의 특성에 따라 라벨을 적용할 수 있을 때 머신러닝 모델을 이용하여 분류를 할 수 있다.
- 예제 데이터는 엘리베이터 UP/DOWN 라벨이 있는 데이터를 이용하여 분류를 실행 한다.

2. 목표

- 기간과 아이템을 선택하고 데이터를 파형별로 구분하고 통계값을 계산한다.
- 모델에 적용하기 위해 원하는 형태로 전처리 한다.
- 정규 분포 형태의 표준스케일링 적용 후 학습 / 테스트 데이터로 나눈다.
- 로지스틱 회귀 모델로 학습 및 예측을 수행한다.
- 정확도와 ROC-AUC 값 구한다.
- 하이퍼파라미터 최적화를 수행한다.

3. 프로세스

3-1. 흐름도



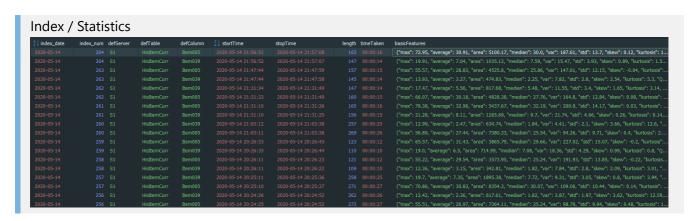
3-2. Load Data

- Select Period & Item

Period: 2020-05-01 ~ 2020-05-14
 Item: ElevatorMain MaxCurrent

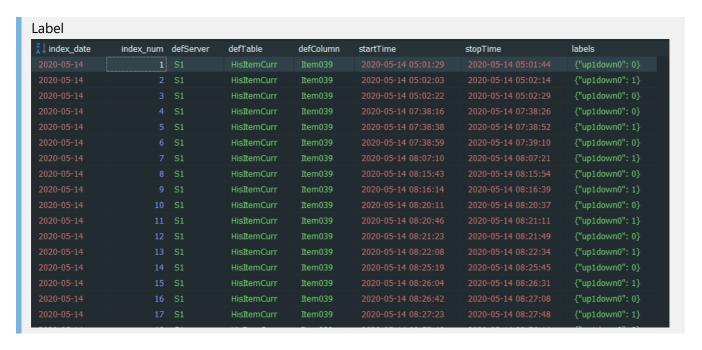
- Indexing & Extraction Statistics

- 1. Indexing
- EndCount: 2초(파형의 시작과 종료를 구분하기 위한 시간)
- 2. Extraction Statistics(17개)
- max
- average
- area
- median
- var
- std
- skew
- kurtosis
- Q1
- Q3
- iqr
- percentile10
- percentile40
- percentile60
- percentile90
- trim_mean10
- trim_mean20



- Labeling

• 저장된 UP/DOWN 신호를 이용하여 라벨링



3-3. Pre-Process

- Pre-Processing

• 모델에 적용하기 위해 원하는 형태로 전처리

Features

```
# DATA

[['14.29' '3.56' '519.52' ... '7.8' '2.83' '2.68']

['21.3' '8.57' '1268.47' ... '11.9' '8.28' '8.9']

['13.87' '3.66' '406.17' ... '8.51' '2.87' '2.42']

...

['17.47' '5.56' '817.68' ... '9.56' '4.98' '5.14']

['13.93' '3.27' '474.83' ... '7.41' '2.51' '2.28']

['19.91' '7.04' '1035.12' ... '10.65' '6.6' '7.02']]

# LENGTH

2963

# TYPE

<class 'numpy.ndarray'>
```

Target

```
# DATA
[1, 0, 1, 0, 0, 1, 0, 1, 1, 0, 1, 1, 0, 0, 1, 1, 0, 0, 1, 0, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1
```

```
# LENGTH
2963
# TYPE
<class 'list'>
```

- Scaling(평균 0, 분산 1로 데이터 분포도 변환)

• 정규 분포 형태의 표준 스케일링 적용

Features

```
# DATA
[[-0.68371451 -1.00025274 -0.44138566 ... -1.37114 -0.94833775
-0.88346797]
[-1.15891996 -1.18069918 -0.62345674 ... -1.47398456 -1.10423386
-1.03055082]
[1.04456246 0.97206883 1.09280422 ... 0.21753789 1.01367185
1.06281441]
...
[-0.76008682 -0.87435987 -0.88429488 ... -0.10452798 -0.92552368
-0.94845807]
[-0.99486094 -1.12614561 -0.5699796 ... -1.48751674 -1.07761745
-1.00318657]
[-1.10517649 -1.13453846 -0.70996628 ... -1.28453405 -1.08902448
-1.02028923]]
```

3-4. Modeling

- Split

- Train 데이터와 Test 데이터를 7:3으로 분할 구성
- 재현성을 위하여 random state(seed)는 0으로 입력한다.
- 분할된 변수: X_train, X_test, y_train, y_test

```
[ 0.92010389  0.78322953 -0.35065294 ... 1.53015932  0.64864681
  0.59078107]]
# X_test
0.99440378]
1.58615572
 1.48696031]
[-0.76008682 -0.87435987 -0.88429488 ... -0.10452798 -0.92552368
 -0.94845807]
[-0.99486094 -1.12614561 -0.5699796 ... -1.48751674 -1.07761745
 -1.00318657
[-1.10517649 -1.13453846 -0.70996628 ... -1.28453405 -1.08902448
 -1.02028923]]
# y train
[1, 1, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 1, 0, 0, 1, 1, 0, 1, 1, 1, 1, 1, 1, 1, 0, 1, 1,
1, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 1,
0, 0, 0, 1, 0, 1, 0, 1, 1, 1, 1, 0, 1, 0, 1, 1, 1, 1, 1, 1, 0, 1, 1, 0]
# y_test
1, 1, 0, 0, 0, 1, 0, 0,
0, 0, 1, 1, 0, 0, 1, 0, 1, 1, 0, 1, 0, 0, 0, 1, 1, 0, 1, 0, 0, 1, 0, 1, 1, 1]
```

- Train / Test

• 로지스틱 회귀로 분류 수행

Train

```
lr_clf = LogisticRegression()
lr_clf.fit(X_train, y_train)
```

Test

```
lr_preds = lr_clf.predict(X_test)
```

3-5. Evaluation

- Evaluation

accuracy & roc_auc

```
# 정확도와 roc_auc 측정
print('accuracy: {:0.3f}'.format(accuracy_score(y_test, lr_preds)))
print('roc_auc: {:0.3f}'.format(roc_auc_score(y_test, lr_preds)))
```

```
accuracy: 0.971
roc_auc: 0.970
```

- 하이퍼파라미터 최적화

- 규제(Regularization)와 규제 강도(alpha)
- C = 1 / alpha
- C값이 작을수록 규제 강도가 큼
- 하이퍼 파라미터 최적화

Regularization & alpha

```
최적 하이퍼 파라미터:{'C': 0.1, 'penalty': 'l1'}, 최적 평균 정확도:0.972
```

4. 결론

- 엘리베이터 데이터의 통계값을 이용한 분류 예측은 약 97%의 정확도로 높은 편이다.
- 로지스틱 회귀를 이용한 이진 분류 예측 성능이 뛰어나다.